

近期前馈式三维重建方法综述

2026 年 5 月

摘要

近年来，三维重建中出现了一类以神经网络前馈预测为主要特征的方法。与传统 SfM/MVS 流程先匹配、再估计相机和三维点不同，DUST3R 等方法直接预测点图、深度、相机或轨迹等几何量，再通过对齐和一致性检查得到可用结果。本文围绕 DUST3R、MASt3R、MASt3R-SfM、Fast3R、VGGT、CUT3R、Spann3R 以及 Gaussian 输出相关工作，梳理近期 3R 方法的主要思路。文章重点不是罗列全部新模型，而是讨论这些方法如何从点图表示走向匹配、多视角输入、视频长序列和可渲染输出。综合已有论文和公开实现看，前馈式方法降低了无位姿输入下的使用门槛，但尺度一致性、动态物体、长序列漂移、外部先验误差和渲染结果的几何可靠性仍需要单独评估。

关键词：前馈式三维重建；3R；DUST3R；MASt3R；VGGT；点图；3D Gaussian Splatting

1 引言

三维重建长期以来主要依赖 SfM 和 MVS。常见流程是先从图像之间建立特征匹配，再估计相机位姿，随后三角化得到稀疏点，最后通过多视角立体、深度融合或 bundle adjustment 改善结果。这套流程的优点是变量清楚，每一步都能和几何约束对应起来；缺点是对图像条件比较敏感。弱纹理、重复结构、反光表面、视角重叠不足和动态物体都会影响匹配与位姿估计。对于手持视频或无序图片集合，传统流程还常常需要筛图、初始化和较长时间的优化。

前馈式三维重建方法试图换一种处理顺序。模型不一定先求出可靠匹配和相机，而是直接从图像预测几何中间量，再把这些中间量接入对齐、筛选或渲染步骤。DUST3R 是这一方向中影响较大的工作，它把图像对映射为稠密 pointmap 和置信度，使深度、局部点云、相机关系和匹配线索可以在同一输出中讨论 [1]。这并不意味着传统几何约束消失了。相反，后续许多工作是在点图表示之后重新引入匹配、SfM、多视角融合或时序状态。

本文把近期 3R 方法按问题而不是按年份组织。首先讨论 DUST3R 的点图接口，因为这是理解后续工作的共同起点。随后讨论 MASt3R 和 MASt3R-SfM，它们说明点图可以服务于匹配和经典 SfM。接着看 Fast3R 与 VGGT，前者关心多图输入的计算代价，后者把相机、深度、点图和轨迹放到同一模型中预测 [2–5]。视频和长序列部分主要讨论 CUT3R、Spann3R 以及少量动态场景工作 [6–10]。最后一部分讨论 3DGS 相关输出方法，因为实际使用中往往需要把几何结果变成可查看、可渲染的表示 [11–14]。




图 1: 传统几何流程与 DUST3R 类前馈方法的简化对比。

近期 3R 相关论文增长很快,如果逐篇介绍,文章很容易变成模型名汇总,反而看不清主要问题。因此,本文只在必要处提到 Depth Anything、DINO、CoTracker、SAM2 等外部先验。它们能够提供深度、特征、跟踪或分割信息,但不是本文的主线模型 [15–18]。

2 从传统流程到点图接口

传统 SfM/MVS 和 DUST3R 类方法的区别,首先体现在中间量的顺序上。传统流程通常先得到二维匹配,再由匹配约束求相机和三维点。DUST3R 则直接预测像素对应的三维位置。对一张图像而言,pointmap 可以理解为一张和原图同尺寸的三维坐标图;对两张图像而言,模型需要让两幅图像中的点图在某个坐标关系下相互对应。置信度用于表示哪些区域更可信,后续对齐和筛选会依赖这一信息。

图 1 给出一个简化对照。这个对照并不是说 3R 方法完全替代 SfM/MVS,而是说明它改变了几何量出现的顺序。传统流程把匹配和相机估计放在前面;3R 方法把稠密几何预测提前,再用对齐和一致性检查补足全局关系。实际系统中,这两类思路常常结合使用。例如 MAST3R-SfM 就把 MAST3R 产生的匹配接回 SfM 流程,而不是跳过所有传统几何步骤 [3]。

点图表示的好处比较直观。首先,它降低了输入条件要求,在相机内外参未知时也能给出几何预测。其次,它把深度、点云和部分对应关系放在同一个输出中,便于后续方法复用。第三,它适合和视觉特征预训练结合。DUST3R 继承了 CroCo 中跨视角补全的思想,说明模型在训练中已经学到一定的跨图像对应能力 [19]。

但点图也带来新的问题。两两图像的点图预测并不能自然保证所有视角处在同一个尺度和坐标系中。若输入是十几张甚至上百张图像,成对组合会带来很大的计算量和对齐压力。动态物体、遮挡区域和反光表面也会使点图预测不稳定。后续工作大多可以看作是在这些问题上作补充:MASt3R 补匹配,Fast3R 补多视角效率,VGGT 补多任务几何输出,CUT3R 和 Spann3R 补长序列状态。

3 DUST3R、MASt3R 与 SfM 接口

DUST3R 的主要贡献是把无位姿输入下的几何预测组织成 pointmap。模型输入两张图像,输出两组稠密三维点和置信度,再通过对齐得到相机、点云或深度等结果 [1]。这种输出形式使图像对之间的几何关系可以直接从网络预测中得到。它的限制也很清楚:成对预测只提供局部关系,若要处理多图集合,还要解决全局对齐和尺度一致性。




图 2: 本文讨论的 3R 方法主线。图中只列正文重点方法。

MASt3R 在这个基础上把重点转向匹配。仅从点图中取对应关系并不总是稳定，尤其是在弱纹理、重复纹理和遮挡边界附近。MASt3R 在点图解码之外加入 dense feature，使像素对应不仅依赖三维预测，也受到局部描述子的约束 [2]。这样得到的匹配更接近“带几何解释的匹配”。它不像传统局部特征那样只在二维图像上比较外观，也不是单纯依赖点图坐标，而是在两者之间建立联系。

MASt3R-SfM 也说明，前馈式模型和经典几何流程可以互补。它把 MASt3R 的匹配能力接入无约束 SfM，用神经匹配改善图像对应，再由 SfM 的全局估计和 bundle adjustment 处理相机与三维结构 [3]。这一点说明，3R 方法并不一定要把传统流程全部替换掉；更合理的理解是，网络预测提供了新的初始几何或匹配信息，传统几何仍然负责全局一致性。

图 2 概括了本文采用的主线。图中没有列出所有论文，只保留与正文关系最直接的几类方法。这样处理比完整时间线更适合本文范围，因为本文关心的是几类问题之间的衔接，而不是按年份记录每一篇新工作。

4 多视角输入：效率与多种几何量

当输入从图像对变成图像集合时，DUST3R 类方法需要面对两个问题。一个是计算问题：图像数量增加后，两两组合会迅速变多。另一个是一致性问题：多个局部点图需要被放到同一场景坐标关系里。Fast3R 主要处理第一个问题，它提出 many-view one-forward-pass 的路线，希望在一次前馈过程中处理大量图像 [4]。这类方法的价值不只在速度数字本身，还在于它把多视角输入从“图像对组合”改写成“集合输入”的问题。

MV-DUST3R+ 处理的是另一类多视角场景。它关注稀疏视角输入，采用多视角 decoder 和参考视角融合来完成单阶段重建 [20]。与 Fast3R 相比，它不主要强调上千张图像规模，而是强调少量视角下的场景重建。二者说明，多视角 3R 并不是一个单一问题。稀疏视角、少量图片和大规模图片集合对模型的要求并不相同。

VGGT 的思路则更偏向多任务几何预测。它把 camera、depth、pointmap 和 tracks 放到同一模型中输出 [5]。这样做的直接好处是接口整齐，使用者可以同时得到相机、深度、轨迹和点图，而不用在不同模型之间来回转换。问题在于，多种输出之间会相互影响。相机估计偏差会影响点云对齐，深度误差会影响几何形状，轨迹错误又会影响视频分析。因此，VGGT 这类模型的结果不能只看单项可视化，而要检查不同输出之间是否一致。

图 3 放入 DUST3R 和 VGGT 的论文方法图，用于说明两类代表方法的差别。

DUST3R 图中重点是从无约束图像集合得到对应点图；VGGT 图中重点是将多种几何任务放在同一预测过程中。这里采用论文图是为了帮助理解方法结构，不据此说明哪一类方法在所有条件下更好。




图 3: DUST3R 与 VGGT 的方法图对照。来源: DUST3R Wang et al. [1], VGGT Wang et al. [5]。

表1 汇总了本文重点讨论的方法。表格只列主线模型和少量相关输出方法，未把所有近期论文都放进来。这样的取舍是为了让比较围绕问题展开，而不是围绕论文数量展开。

表 1: 本文重点讨论的 3R 方法。

方法	主要输入/ 输出	主要作用	需要注意的问题
DUSt3R	图像对, 点图与 置信度	提供无位姿输入下的稠密几何预测	多视角尺度和全局一致性仍需后处理
MASt3R	图像对, 点图与 dense feature	用三维几何改进匹配	匹配结果仍要经过筛选和全局检查
MASt3R-SfM	图像集合, SfM 结果	将 MASt3R 匹配接入传统 SfM	效果依赖图像覆盖、匹配质量和全局优化
Fast3R	多图输入, 三维 几何	减少大量成对组合带来的开销	速度结果需要结合分辨率和硬件条件阅读
MV-DUSt3R+	稀疏视角, 场景 几何	处理少量视角下的单阶段重建	适用条件与大规模图像集合不同
VGGT	多视角输入, 相机/深度/点 图/轨迹	在同一模型中预测多种视觉几何量	多任务输出之间可能存在误差传递
CUT3R	视频或连续图 像, 递推状态	处理连续输入中的历史信息	状态更新可能累积早期错误
Spann3R	图像流, 空间记 忆	用外部记忆保存场景信息	记忆更新和漂移控制仍是难点
InstantSplat/ NoPoSplat	稀疏视角, Gaussian 表示	将重建结果转为可渲染输出	渲染效果不能直接等同于几何准确

5 视频、动态场景与长序列

视频输入和静态图像集合不同。视频帧有时间顺序, 相邻帧之间通常变化较小, 因此可以利用历史信息; 但视频中也更容易出现运动模糊、遮挡和动态物体。若仍按静态场景理解所有像素, 移动的人、车或物体会被错误地放进静态几何中, 导致相机和点图都出现偏差。

CUT3R 采用 persistent recurrent state 处理连续输入 [6]。它的基本思想是, 在新图像到来时不只看当前帧, 也保留前面帧中已经形成的几何状态。这样的设计适合视频或流式输入, 但也带来一个问题: 如果早期状态中保存了错误, 后续帧可能继续继承这些错误。Spann3R 则使用 spatial memory 保存与场景空间相关的信息 [7]。与递推状态相比, 空间记忆更强调对场景结构的存储和访问, 但它同样需要处理遮挡、重复纹理和长期漂移。

动态场景方法可以看作对静态假设的补充。MonST3R 在 DUSt3R 风格的点图基础上处理存在运动的场景, 并引入与动态区域相关的置信度或 mask [8]。Easi3R 不重新训练主模型, 而是从 DUSt3R 的注意力中分离运动信息, 属于推理时修正思路 [9]。RayMap3R 则利用 RayMap 与图像分支之间的差异识别动态干扰 [10]。这些工作都说明, 动态物体不是简单的噪声, 而是会改变几何解释的因素。

在本文的范围内, 动态方法主要作为长序列重建的限制条件和扩展方向来讨论。当输入视频中有明显运动时, 静态重建模型的输出需要额外检查, 不能只看整体点云是否

表 2: 3R 方法应用时应记录的证据。

记录项	需要记录的内容	原因
输入条件	图像数量、分辨率、视角间隔、是否有动态物体	这些因素会直接影响匹配、点图和相机估计
运行条件	模型权重、硬件、耗时、显存、是否使用外部先验	速度和显存结论离不开具体环境
几何检查	深度、点云尺度、相机轨迹、重投影或跨视角一致性	渲染结果不能单独证明几何准确
动态区域	运动物体、遮挡边界、mask 或置信度变化	动态区域常是静态重建失败来源
失败样本	明显错误的输入、输出截图和可能原因	失败样本比单个成功 demo 更能说明适用范围
许可与复现	代码、权重、许可证、数据来源	决定方法是否能被实际使用和复查

成形。实际评价时，动静分离、遮挡边界、运动区域的时间稳定性都应单独观察。

6 Gaussian 输出与应用评价

很多 3R 模型的直接输出是点图、深度、相机或轨迹，但实际使用时往往还需要可查看、可渲染的结果。3D Gaussian Splatting 提供了一种实时渲染质量较好的表示方式，因此自然被接入到无位姿或稀疏视角重建中 [11]。InstantSplat 使用稠密立体先验与 Gaussian Bundle Adjustment 处理稀疏视角；NoPoSplat 从稀疏无位姿图像预测规范坐标下的 Gaussian；Splatt3R 则从未标定图像对预测 Gaussian 属性 [12–14]。

需要注意的是，Gaussian 输出解决的主要是可视化和渲染层面的问题。渲染图视觉效果较好，不等于几何一定准确。一个结果可能在训练视角附近看起来平滑，但相机轨迹、物体边界或视角外区域仍有错误。因此，评价这类方法时应把渲染质量和几何质量分开。新视角图像、点云尺度、相机轨迹、遮挡边界和失败样本都需要一起记录。

外部先验也需要谨慎使用。Depth Anything、Depth Pro、DINO、CoTracker 和 SAM2 可以分别提供深度、视觉特征、长程跟踪或视频分割信号 [15–18, 21]。这些信息能够帮助 3R 系统处理弱纹理、动态区域或尺度估计，但它们也有自己的失效场景。例如，分割错误会影响动静区域判断，深度先验在域外图像上可能产生尺度偏差，跟踪错误会污染长序列状态。把先验接入系统时，应记录先验来自哪里、是否经过检查，以及与 3R 输出冲突时如何处理。

表 2 给出一个较实际的评价清单。这个清单不追求复杂，而是提醒读者不要把“代码能运行”和“重建质量可靠”混在一起。

7 讨论与结论

从上述几类工作可以看出，近期前馈式三维重建的主线并不是简单地“用网络取代几何”。更准确地说，网络被用来提前预测某些几何中间量，而传统几何中的对齐、一

致性检查和全局约束仍然重要。DUST3R 给出了点图接口，MASt3R 把点图和匹配联系起来，MASt3R-SfM 又把这种匹配接回 SfM。Fast3R 和 VGGT 处理多视角输入时，一个更关注计算规模，一个更关注多种几何量的共同输出。CUT3R 和 Spann3R 说明视频和长序列需要状态或记忆，而 Gaussian 相关方法则说明下游常常需要可渲染表示。

这些方法仍有一些共同困难。第一是尺度和坐标一致性。局部预测容易得到看似合理的点图，但多视角或长序列中需要把它们放到同一几何关系里。第二是动态物体和遮挡。静态重建假设在视频中经常被破坏，动态区域若没有被识别，可能会影响相机和点云。第三是长序列误差累积。递推状态和空间记忆能够保存历史信息，也可能保存错误。第四是评价标准。论文中的 benchmark、官方 demo、本地运行记录和真实应用条件并不等价，需要分开说明。

因此，评价这类方法时不宜只关注论文数量或演示效果。更关键的问题是：点图解决了什么，匹配为什么还需要保留，为什么多视角输入会带来计算和一致性问题，视频为什么需要状态，Gaussian 输出为什么不能直接代表几何准确。按这些问题来看，DUST3R 之后的 3R 方法已经形成了较清楚的发展线索，但其应用边界仍要通过失败样本、跨视角检查和复现实验来确认。

参考文献

- [1] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUST3R: Geometric 3D Vision Made Easy, 2023. URL <https://arxiv.org/abs/2312.14132>. arXiv preprint.
- [2] Vincent Leroy, Yohann Cabon, and Jerome Revaud. Grounding Image Matching in 3D with MASt3R, 2024. URL <https://arxiv.org/abs/2406.09756>. arXiv preprint.
- [3] Bardienus Duisterhof, Lojze Zust, Philippe Weinzaepfel, Vincent Leroy, Yohann Cabon, and Jerome Revaud. MASt3R-SfM: a Fully-Integrated Solution for Unconstrained Structure-from-Motion, 2024. URL <https://arxiv.org/abs/2409.19152>. arXiv preprint.
- [4] Jianing Yang, Alexander Sax, Kevin J. Liang, Mikael Henaff, Hao Tang, Ang Cao, Joyce Chai, Franziska Meier, and Matt Feiszli. Fast3R: Towards 3D Reconstruction of 1000+ Images in One Forward Pass, 2025. URL <https://arxiv.org/abs/2501.13928>. arXiv preprint.
- [5] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer, 2025. URL <https://arxiv.org/abs/2503.11651>. arXiv preprint.
- [6] Qianqian Wang, Yifei Zhang, Aleksander Holynski, Alexei A. Efros, and Angjoo Kanazawa. Continuous 3D Perception Model with Persistent State, 2025. URL <https://arxiv.org/abs/2501.12387>. arXiv preprint.

- [7] Hengyi Wang and Lourdes Agapito. 3D Reconstruction with Spatial Memory, 2024. URL <https://arxiv.org/abs/2408.16061>. arXiv preprint.
- [8] Junyi Zhang, Charles Herrmann, Junhwa Hur, Varun Jampani, Trevor Darrell, Forrester Cole, Deqing Sun, and Ming-Hsuan Yang. MonST3R: A Simple Approach for Estimating Geometry in the Presence of Motion, 2024. URL <https://arxiv.org/abs/2410.03825>. arXiv preprint.
- [9] Xingyu Chen, Yue Chen, Yuliang Xiu, Andreas Geiger, and Anpei Chen. Easi3R: Estimating Disentangled Motion from DUST3R Without Training, 2025. URL <http://arxiv.org/abs/2503.24391>. arXiv preprint.
- [10] Feiran Wang, Zezhou Shang, Gaowen Liu, and Yan Yan. RayMap3R: Inference-Time RayMap for Dynamic 3D Reconstruction, 2026. URL <https://arxiv.org/abs/2603.20588>. arXiv preprint.
- [11] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkuehler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering, 2023. URL <https://arxiv.org/abs/2308.04079>. arXiv preprint.
- [12] Zhiwen Fan, Wenyan Cong, Kairun Wen, Kevin Wang, Jian Zhang, Xinghao Ding, Danfei Xu, Boris Ivanovic, Marco Pavone, Georgios Pavlakos, Zhangyang Wang, and Yue Wang. InstantSplat: Sparse-view Gaussian Splatting in Seconds, 2024. URL <https://arxiv.org/abs/2403.20309>. arXiv preprint.
- [13] Botao Ye, Sifei Liu, Haoifei Xu, Xueting Li, Marc Pollefeys, Ming-Hsuan Yang, and Songyou Peng. No Pose, No Problem: Surprisingly Simple 3D Gaussian Splats from Sparse Unposed Images, 2024. URL <https://arxiv.org/abs/2410.24207>. arXiv preprint.
- [14] Brandon Smart, Chuanxia Zheng, Iro Laina, and Victor Adrian Prisacariu. Splatt3R: Zero-shot Gaussian Splatting from Uncalibrated Image Pairs, 2024. URL <https://arxiv.org/abs/2408.13912>. arXiv preprint.
- [15] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth Anything V2, 2024. URL <https://arxiv.org/abs/2406.09414>. arXiv preprint.
- [16] Maxime Oquab, Timothee Darcet, Theo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, et al. DINOv2: Learning Robust Visual Features without Supervision, 2023. URL <https://arxiv.org/abs/2304.07193>. arXiv preprint.
- [17] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker: It is Better to Track Together, 2023. URL <https://arxiv.org/abs/2307.07635>. arXiv preprint.

- [18] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, et al. SAM 2: Segment Anything in Images and Videos, 2024. URL <https://arxiv.org/abs/2408.00714>. arXiv preprint.
- [19] Philippe Weinzaepfel, Vincent Leroy, Thomas Lucas, Romain Brégier, Yohann Cabon, Vaibhav Arora, Leonid Antsfeld, Boris Chidlovskii, Gabriela Csurka, and Jerome Revaud. CroCo: Self-Supervised Pre-training for 3D Vision Tasks by Cross-View Completion, 2022. URL <https://arxiv.org/abs/2210.10716>. NeurIPS 2022.
- [20] Zhenggang Tang, Yuchen Fan, Dilin Wang, Hongyu Xu, Rakesh Ranjan, Alexander Schwing, and Zhicheng Yan. MV-DUSt3R+: Single-Stage Scene Reconstruction from Sparse Views In 2 Seconds, 2024. URL <https://arxiv.org/abs/2412.06974>. arXiv preprint.
- [21] Aleksei Bochkovskii, Amael Delaunoy, Hugo Germain, Marcel Santos, Yichao Zhou, Stephan R. Richter, and Vladlen Koltun. Depth Pro: Sharp Monocular Metric Depth in Less Than a Second, 2024. URL <https://arxiv.org/abs/2410.02073>. arXiv preprint.