

问题引入：高性能模型与部署成本的博弈

教师-学生范式

通过高成本监督训练，获得高效能部署模型。

教师-学生范式（Teacher-Student Paradigm）已不仅限于传统的模型压缩。它本质上是一种非对称的监督传递框架：通过引入强模型、伪标签或稳定教师产生的丰富信号，将海量无标签数据的隐式规律，转化为可训练的显式目标。

直观理解

暗知识传递

教师分布保留了类别间的语义相似性。这种“结构化先验”比单一真值标签具有更高信息熵。

形式化表达

目标函数体系

涵盖任务监督、分布对齐与特征一致性。通过温度系数暴露分布的长尾信息。

实践落地

Depth Anything

探讨如何利用该范式构建深度估计的“数据引擎”，将无标签真实图像转化为稠密监督信号。

核心矛盾

精准的模型通常伴随着沉重的推理开销。

教师 (Teacher)

通常是超大参数模型、集成模型或冻结的强编码器。负责在训练阶段输出“参考答案”。

高算力

学生 (Student)

轻量化网络，旨在拟合并泛化教师的行为。在部署阶段，教师模型被完全舍弃。

低功耗

监督 (Signal)

不再仅限于 Hard Label。它包含 Logits 结构、中间特征图及多视图一致性约束。

多模态

教师-学生模型本质上是在用“训练时的复杂度”补偿“推理时的模型容量”。

范式理解

大规模预训练模型（如 Vit-L/G）虽然具备极强的泛化力，但其推理延迟和显存占用限制了在移动端或实时场景的部署。教师-学生架构通过“离线繁重训练，在线轻量推理”解决了这一难题。

逻辑示意：监督流向

数据池

输入样本

含标/无标/真实分布
强教师

生成目标

输出高维、平滑分布
软信号

暗知识载体

保留决策边界
轻学生

拟合更新

独立推理模型

从模型压缩到监督扩展	
训练态	部署态
教师+学生：计算密集	仅学生：低延迟

语义空间的拓扑信息

硬标签给出正确答案，软分布揭示语义联系。

在一张“猫”的分类任务中，Hard Label 将除“猫”以外的概率强制设为 0。而 Teacher 输出的 Soft Distribution 可能显示：猫 (0.72) 与狐狸 (0.15) 的相似度远高于猫与汽车 (0.01)。这部分信息即为“暗知识”。

Hard Label

独热编码，将非正确类别全部抹除，损失了语义空间的连续性。

信息坍缩

Soft Label

包含次优选项的相对概率，定义了更精细、更抗噪的决策边界。


分布保留

暗知识

隐藏在错误类别分布中的几何关系，引导学生学习更高阶的特征。

Dark Knowledge

典型教师分布可视化



学生通过模仿这组分布，获得了教师对物体相似性的“认知模型”。

目标函数：学生同时学真实答案和教师分布

真实标签保证任务不跑偏；教师分布补充类别关系、不确定性和中间表示结构。

$$L_{\text{total}} = \alpha L_{\text{task}} + \beta \tau^2 D_{\text{KL}}(q_T || q_S) +$$

任务损失

通常为 CE 或 L1，确保学生模型对真实标签 (y) 的预测精度。

软目标蒸馏

对齐平滑后的概率分布。 τ^2 用于抵消梯度量级缩放。

γL_{feat}

特征对齐

对齐 Encoder 产生的语义表示，如 DINOv2 的中间特征图。

δL_{cons}

一致性约束

不同扰动视图下的预测稳定性，常见于半监督训练。

公式推导

任务损失 + 分布对齐 + 特征对齐

$$q_i = \exp(z_i/\tau) / \sum \exp(z_j/\tau)$$

$$\alpha + \beta + \gamma + \delta = 1$$

各损失项的**平衡权重**。在 Depth Anything

$$D_{\text{KL}}(T || S)$$

KL 散度。度量学生预测与教师预测在信息熵

动态博弈流程

在扰动视图下恢复来自教师的稳定映射。

现代教师-学生范式（如 FixMatch, Depth Anything）通常采用“非对称增强”策略：教师处理干净数据以输出稳定信号；学生处理极具挑战的增强数据。这种对抗式设计迫使学生学习场景的鲁棒几何结构。

1. 目标锁定

Teacher 对原始图像 (I) 进行推理，生成作为 Pseudo Label 的 Logits 或深度图。

Stability

2. 挑战输入

Student 接收图像 I 的增强版本 (I')，包含噪声、Cutout 或色彩畸变。

Perturbation

3. 损失传导

梯度仅通过 Student 模型回传。Teacher 通常被冻结或以 EMA 形式缓慢更新。

Update



监督容器的演进

从单纯概率模仿到表示空间对齐。



分类蒸馏	利用软概率 (Soft-max) 分布传递暗知识。	Logits
半监督学习	Mean Teacher 范式：利用 EMA 维持无标数据的预测稳定性。	EMA
稠密预测	Depth Anything：将 Teacher 预测的深度图作为 Pseudo Ground Truth。	Pseudo Map
表示迁移	DINOv2 等语义特征作为几何学习的辅助约束。	Feature

瓶颈与局限

学生会忠实地“复刻” 教师的系统性误差。

范式的效能上限取决于教师信号的纯净度。如果教师在特定极端场景（如高光反射、细长物体）存在先验偏差，这种偏差会被学生模型视为“真理”从而固化为系统性偏见。

噪声反馈环

错误的伪标签会误导学生。若无置信度阈值过滤，训练将陷入发散。

Noise

分布偏移

当无标签数据进入 OOD（分布外）区域，教师的预测将变得不可靠。

OOD Shift

容量错位

极小规模学生可能因拟合能力不足，反而由于过强的蒸馏约束抑制了主任务学习。

Constraint

边界条件

有效蒸馏的先决条件

分布覆盖度

无标签图像必须涵盖真实的推理分布。

目标平滑度

教师输出应比 Hard Label 具有更小的方差。

干扰强度

强扰动是迫使学生学习“不变性”的唯一途径。

指标校准

必须保留少量真值用于周期性性能对齐。

错误传播 · 泛化瓶颈 · 训练稳定性

需求驱动的理论转向

Align3R 暴露了单目深度的“数据饥渴”。

在 Align3R 的动态视频对齐研究中，我们需要在 3D 空间中建立跨帧的几何一致性。然而，由于激光雷达真值 (LiDAR GT) 的稀疏性和高成本，单目深度估计的精度成为了制约整个三维重建系统的核心瓶颈。

这驱使我们寻求一种方案：既然真值不够，能否用教师-学生模型将海量 RGB 转化为几何先验？

Align3R 痛点

深度图边缘模糊、动态物体深度抖动，导致三维对齐失败。

Pain Point

转向逻辑

借鉴教师-学生范式，利用 Depth Anything 构建更强的通用深度骨干。

Pivot

案例脉络

Align3R 几何需求 → 深度数据瓶颈 → 蒸馏方案引入

从对齐需求到深度感知

Align3R 对深度的依赖：

相机位姿解算、稠密三维点云构建、遮挡处理。

↓ 呼唤更强深度模型

Depth Anything 的响应：

通过 62M 伪标签蒸馏，获得具备强泛化力的稠密几何映射。

单目深度估计在此不仅是下游任务，更是解决复杂几何对齐的基础预处理器。

核心方法论

利用 62M 无标签图像突破监督瓶颈。

v1 的核心逻辑在于：既然标注极其昂贵，那就让教师去“自动标注”全世界。通过在海量真实图像上生成伪深度（Pseudo Depth），学生模型获得了远超人工有限真值集的几何认知力。

强教师训练

1.5M


基于 6 个开源真值集训练具备基础能力的初始教师模型。

伪标注扩展

62M

利用 Teacher 模型将海量真实图像转化为稠密的伪深度数据。

关键技术：引入冻结的 DINOv2 作为语义先验教师，辅助学生解决几何模糊问题。




实验观测

在大规模真实分布上学习，而非在真值集上过拟合。

实验证明，在零样本（Zero-shot）测试集上，Depth Anything 的表现优于在特定真值集上训练的监督模型。这揭示了“场景覆盖度”在稠密预测任务中甚至比“绝对精度”更具决定性。

Dataset	Indoor	Outdoor	Label	# Images
Labeled Datasets				
BlendedMVS [77]	✓	✓	Stereo	115K
DIML [13]	✓	✓	Stereo	927K
HRWSI [68]	✓	✓	Stereo	20K
IRS [62]	✓		Stereo	103K
MegaDepth [33]		✓	SfM	128K
TartanAir [63]	✓	✓	Stereo	306K
Unlabeled Datasets				
BDD100K [82]		✓	None	8.2M
Google Landmarks [65]		✓	None	4.1M
ImageNet-21K [50]	✓	✓	None	13.1M
LSUN [81]	✓		None	9.8M
Objects365 [53]	✓	✓	None	1.7M
Open Images V7 [30]	✓	✓	None	7.8M
Places365 [88]	✓	✓	None	6.5M
SA-1B [27]	✓	✓	None	11.1M

Table 1. In total, our Depth Anything is trained on 1.5M labeled images and **62M unlabeled images** jointly.



结论推导：

伪标签虽然精度有限，但其提供的“规模感”和“多样性”弥补了人工 LiDAR 数据在长尾场景（如极远物体、复杂材质）的缺失。

验证环节

Method	Encoder	KITTI [18]		NYUv2 [55]		Sintel [7]		DDAD [20]		ETH3D [52]		DIODE [60]	
		AbsRel	δ_1	AbsRel	δ_1	AbsRel	δ_1	AbsRel	δ_1	AbsRel	δ_1	AbsRel	δ_1
MiDaS v3.1 [5]	ViT-L	0.127	0.850	0.048	<u>0.980</u>	0.587	0.699	0.251	0.766	0.139	0.867	0.075	0.942
	ViT-S	0.080	0.936	0.053	0.972	0.464	0.739	0.247	0.768	0.127	0.885	0.076	0.939

迭代逻辑

如果教师更准，学生的性能上限就更高。

v2 指出 v1 的瓶颈在于真实图像伪标签中存在的几何瑕疵（如边缘空洞）。其核心策略是：先通过高质量的合成数据（Synthetic Data）培养一个“完美的几何教师”，再将其知识迁移到真实分布。

合成数据教师	在 595K 极其干净、几何精确的合成样本上训练，捕捉完美物理结构。	Quality
跨域迁移	利用高质量教师为 62M 真实图像重塑伪深度，降低标签噪声。	Transfer
全量化部署	通过知识蒸馏推出 S、M、L 多规模学生模型，适配不同算力平台。	Scaling




Figure 7: Depth Anything V2. We first train the most capable teacher on precise synthetic images. Then, to mitigate the distribution shift and limited diversity of synthetic data, we annotate unlabeled real images with the teacher. Finally, we train student models on high-quality pseudo-labeled images.




Figure 5: Qualitative comparison of different vision encoders on synthetic-to-real transfer. Only DINOv2-G produces a satisfying prediction. For quantitative comparisons, please refer to Section B.6.




Figure 6: Failure cases of the most capable DINOv2-G model when purely trained on synthetic images. Left: the sky should be ultra far. Right: the depth of the head is not consistent with the body.

从单纯追求“数据量”进化为“量与质”的双重对齐。

汇报总结

从单纯的模型压缩，到大规模监督生成器。

教师-学生架构已经成为深度学习时代处理“难以获取真值的稠密预测任务”的核心基础设施。

理论收束

通过损失体系和温度控制，实现跨模型容量的知识稳定传递。

Mechanism

案例启示

Depth Anything 系列证明了：合成数据与伪标签蒸馏的结合，是构建通用视觉模型的最短路径。

Vision

讨论要点：

- 角色关联：**Align3R 定义了对高一致性深度的迫切需求，而 Depth Anything 则利用教师-学生范式完美填补了这一真值缺口。
- 范式核心：**优秀的教师并非给出标准答案，而是通过软分布向学生展示“解决问题的概率结构”。

“最好的蒸馏，是让学生在被扰动的视野中，看到最稳定的几何本质。”