



教师-学生模型汇报讲稿（分工版）

对应页面： `index_12.html`

分工：A 讲第 1-7 页，B 讲第 8-12 页。

建议总时长：12-15 分钟。A 约 8 分钟，B 约 6 分钟，最后留 1 分钟答问。

A：第 1-7 页，讲清教师-学生模型的原理

第 1 页：封面

讲解目标

建立整场报告的问题意识：教师-学生模型不是单纯模型压缩，而是一种用高成本训练监督换低成本部署模型的范式。

讲稿

大家好，我们这次汇报的主题是教师-学生范式。这个方法最早经常和模型压缩联系在一起：用一个大模型教一个小模型，让小模型在推理时更快、更省资源。

但现在它的含义已经更宽了。教师不一定只是一个大分类模型，也可以是一个伪标签生成器、一个平均教师、一个预训练编码器，或者一个能提供语义特征的基础模型。学生也不只是“缩小版模型”，而是一个在教师监督下学会某种能力、最后能独立部署的模型。

这次汇报会先讲原理：教师到底教什么，学生怎么学，损失函数怎么写；然后再落到 Depth Anything，解释它如何用教师-学生范式解决单目深度估计中的监督不足问题。

翻页脚本

按右键进入第 2 页：

“先从最现实的问题开始：为什么我们需要教师，而不是直接部署最强模型？”

第 2 页：研究动机

讲解目标

说明教师-学生模型的基本结构：教师、学生、监督信号，以及训练/推理阶段的成本分配。

讲稿

教师-学生模型的动机其实很直接：高性能模型通常很贵。比如大规模预训练模型、模型集成，或者大型视觉编码器，它们在训练和标注阶段非常有价值，但如果直接部署到移动端、机器人或实时系统里，推理延迟和显存开销就会成为问题。

所以教师-学生范式做了一件事：把复杂度放在训练阶段。教师可以很大、很慢、很贵，它负责产生更丰富的监督信号；学生则相对轻量，训练时学习这些信号，推理时独立工作。

这里的监督信号也不只是人工 hard label。它可以是概率分布、伪标签、深度图、特征图、注意力图，甚至是不同增强视图之间的一致性目标。也就是说，教师真正传递的是一种“模型行为”。

翻页脚本

“那教师给出的信号为什么会比普通标签更有信息量？第 3 页用分类任务做一个最小例子。”

第 3 页：软分布与暗知识

讲解目标

用 hard label 和 soft label 对比，讲清“暗知识”是什么。

讲稿

在普通分类里，人工标签通常是 hard label。比如一张图的标签是“猫”，那么猫是 1，其他类别全是 0。这个标签能告诉模型正确答案，但它把其他类别之间的关系全部抹掉了。

教师模型输出的是 soft label，也就是一个概率分布。比如这张图被判断为猫的概率最高，但狐狸、狗也可能有一点概率，而车几乎没有概率。这个分布里包含一个很重要的信息：猫和狐狸的距离，比猫和车更近。

Hinton 等人把这种隐藏在错误类别概率里的结构信息称为 dark knowledge，暗知识。学生模仿

的不只是“答案是猫”，而是教师对类别相似性和决策边界的判断方式。

翻页脚本

“有了这个直觉之后，我们就能进入公式：学生训练时到底同时优化哪些目标？”

第 4 页：目标函数

讲解目标

讲清总损失：任务监督、蒸馏损失、温度、权重，以及特征对齐的作用。

讲稿

这一页是教师-学生模型的数学骨架。学生不是只学教师，也不是抛弃真实标签。常见做法是把真实标签监督和教师分布监督联合起来。

任务损失，比如交叉熵，保证学生不会偏离最终评价目标。蒸馏损失，比如 KL 散度，让学生的输出分布接近教师的输出分布。这里的温度系数 τ 用来平滑 softmax 分布，让非最大类别也有可学习的信号；前面的权重 λ 用来平衡“听真实标签”和“听教师分布”的比例。

如果进入视觉任务，尤其是 Depth Anything 这种稠密预测任务，还会加入特征对齐项。比如 `L_feat` 让学生的中间特征接近 DINOv2 这样的预训练语义特征。这样学生不是只拟合深度数值，也能保留物体边界、区域一致性和前景背景结构。

翻页脚本

“公式说明了学什么，下一页看训练循环里这些信号如何流动。”

第 5 页：训练过程

讲解目标

说明教师生成目标、学生处理扰动输入、梯度只更新学生。

讲稿

教师-学生训练通常可以拆成三步。

第一步，教师看原始图像，生成稳定目标。这个目标可能是分类概率、伪标签，也可能是深度图。第二步，学生通常接收增强后的图像，比如有遮挡、裁剪、颜色扰动或其他强增强。第三步，学生要在这个更难的输入条件下恢复教师给出的目标，损失只回传到学生模型。

这个设计的目的不是让学生死记硬背教师输出，而是让它学会不变性。也就是说，即使输入被扰动，学生仍然要恢复稳定预测。像 Depth Anything 里，教师给出伪深度，学生在强扰动下学习深度结构，就是这个逻辑。

翻页脚本

“教师信号并不只有输出概率，下一页把教师信号的几种形态展开。”

第 6 页：教师信号的多维表达

讲解目标

说明教师可以提供输出层、隐藏层、权重空间三类信号。

讲稿

教师-学生模型里，教师的形式很灵活。第一种是输出层教师，比如分类概率、深度图、分割图，这类信号直接作为学生的预测目标。

第二种是隐藏层教师，也就是特征表示对齐。学生不一定只模仿最后输出，还可以模仿教师中间层的表示。DINOv2 在 Depth Anything 里就可以这样理解：它提供的不是人工语义标签，而是一个带有语义结构的特征空间。

第三种是权重空间的教师，比如 Mean Teacher。教师不是一个完全独立的大模型，而是学生参数的指数滑动平均。这样教师预测更稳定，适合半监督一致性训练。

所以教师-学生模型的重点不是“教师一定是大模型”，而是教师能否提供比普通标签更稳定、更丰富的训练信号。

翻页脚本

“但教师也不是万能的。第 7 页要讲这个方法的边界和风险。”

第 7 页：风险分析

讲解目标

讲清教师-学生范式的风险：教师偏差、伪标签噪声、分布偏移、学生容量不足。

讲稿

教师-学生模型的一个核心风险是：学生会很认真地学习教师的错误。如果教师在某些场景中有系统性偏差，比如透明物体、反光区域、极端光照，学生很可能把这些错误也继承下来。

第二个风险是伪标签噪声。伪标签不是人工真值，它本质上是教师预测。如果没有置信度过滤、数据清洗或真值校准，错误伪标签会形成噪声反馈。

第三个风险是分布偏移。如果无标签数据和实际测试场景差异很大，教师可能会过度自信地产生错误监督。第四个是容量错位，如果学生太小，可能学不动复杂教师；如果强行蒸馏，反而会影响任务损失。

所以教师-学生模型有效的条件是：数据覆盖足够广，教师目标足够平滑，扰动强度合适，并且要保留真值集做校准。

交接脚本

“到这里，前半部分把教师-学生模型的基本机制讲完了：它为什么需要教师，教师给什么，学生怎么学，以及它有什么风险。后半部分我们把这个框架放到具体任务里，看它怎样在 Depth Anything 中解决单目深度估计的问题。”

B：第 8-12 页，讲 Depth Anything 与 Align3R 案例

第 8 页：从 Align3R 到单目深度估计

讲解目标

把案例入口讲自然：我们为什么从 Align3R 进入 Depth Anything。

讲稿

后半部分我们从 Align3R 切入。Align3R 关注的是动态视频里的深度对齐问题。简单说，单帧深度模型可能给每一帧生成看起来不错的深度图，但视频不是一堆独立图片。视频里还要求跨帧尺度一致、相机位姿一致，动态区域也不能在几何上乱跳。

这就暴露了一个问题：高质量、稳定的深度从哪里来？真实深度标注很贵，尤其是动态场景、开放世界和复杂室外场景，很难拿到足够多的真值。

所以我们自然转向 Depth Anything。它的意义在于：用教师-学生范式，把大量无标签 RGB 图像转成可训练的伪深度监督。也就是说，Align3R 让我们看到深度在几何对齐中的重要性；Depth Anything 则回答了单帧深度监督如何大规模获得。

翻页脚本

“接下来先看 Depth Anything v1，它把教师模型用成了一个数据引擎。”

第 9 页：Depth Anything v1

讲解目标

讲清 v1 的核心：教师给 62M 无标签真实图像生成伪深度，DINOv2 提供语义特征先验。

讲稿

Depth Anything v1 的核心逻辑是：既然人工深度标注很贵，就让教师模型去自动生成伪深度标签。

它先基于约 1.5M 有标注深度数据训练一个初始教师，然后用这个教师去处理 62M 无标签真实图像，生成大规模伪深度。这样学生看到的训练分布就不再局限于少量真值数据，而是扩展到更丰富的真实世界图像。

这里还有一个关键点：Depth Anything 不只是拟合伪深度图。它还引入冻结的 DINOv2 作为语义特征教师。DINOv2 不提供“人、车、天空”这种人工语义标签，而是在特征空间里提供物体边界、区域相似性和前景背景关系。

所以学生最终输出的是深度图，但中间过程会使用语义结构。准确讲法是：Depth Anything 不是让学生输出语义，而是让学生用语义来预测深度。

翻页脚本

“那这些伪标签到底有没有带来有效提升？第 10 页看论文里的证据链。”

第 10 页：证据链与零样本泛化

讲解目标

说明 v1 为什么能泛化：真实分布覆盖、伪标签规模、零样本测试。

讲稿

这一页重点看证据，而不是只记住“62M”这个数字。

Depth Anything v1 的关键证据是零样本泛化。所谓零样本，就是模型没有针对这些测试集专门训练，但仍然在多个数据集上表现很好。这说明它不是只在某个小真值集上过拟合，而是在大规模真实图像分布中学到了更通用的深度结构。

伪标签本身不一定比人工真值更精确，但它带来的优势是覆盖范围。真实世界里的室内、室外、天气、物体、视角变化，都可以通过无标签数据进入训练。只要教师质量足够稳定，学生就能从大量样本中学到更鲁棒的深度先验。

因此 v1 的贡献不是简单扩大数据量，而是把无标签真实图像转化成了可训练的稠密监督。

翻页脚本

“v1 解决了数据规模问题，但伪标签质量仍然是瓶颈。v2 就是在这个方向上继续推进。”

第 11 页：Depth Anything v2

讲解目标

讲清 v2 的变化：从追求数据量转向提高教师标签质量。

讲稿

Depth Anything v2 的问题意识是：v1 虽然用了大量真实无标签图像，但教师生成的伪深度仍然可能有边缘空洞、几何不准和细节错误。学生学习这些标签时，上限会被教师质量限制。

所以 v2 把重点转向“标签信噪比”。它先用高质量合成数据训练一个更干净的几何教师。合成数据的优势是几何真值更精确，边界和深度关系更可控。然后再用这个更强教师去给真实图像生成伪深度。

这样做相当于两步迁移：先在合成世界里训练出几何能力，再把这种能力通过伪标签迁移到真实图像分布。最后再训练不同规模的学生模型，适配不同部署需求。

所以 v2 相比 v1 的变化可以概括为：v1 主要解决数据量，v2 进一步解决标签质量。

翻页脚本

“最后我们把原理和案例收回来，看教师-学生模型在这里扮演的角色发生了什么变化。”

第 12 页：总结与讨论

讲解目标

总结教师-学生模型的角色变化：从模型压缩到大规模监督生成器。

讲稿

回到最开始的问题，教师-学生模型最初常被理解为模型压缩：大教师教小学生，小学生更容易部署。

但通过 Depth Anything 这个案例可以看到，它现在已经不只是压缩方法，而是一种大规模监督生成机制。教师负责把难以人工标注的真实图像转成可训练目标，学生负责把这些目标吸收成可部署能力。

在 Depth Anything 里，教师生成伪深度，DINOv2 提供语义特征先验，学生最终输出深度图。这个过程也解释了我们和 Align3R 的连接：Align3R 需要稳定、一致的深度作为几何基础，而 Depth Anything 提供了强单帧深度先验。

因此，这个案例展示的是一个完整链条：教师学生范式扩展监督，Depth Anything 学到强深度先验，Align3R 等几何模型再把深度组织进一致的 3D/视频几何系统里。

结束脚本

“我们的汇报到这里结束。最后可以用一句话概括：教师-学生模型不是简单让小模型模仿大模

型，而是把昂贵、稀缺或隐式的知识转化成学生能够学习的大规模监督。”

分工衔接脚本

A 讲完第 7 页后交给 B

“前 7 页我们主要解释了教师-学生模型的原理：教师提供更丰富的监督，学生通过损失函数和训练循环吸收这些信号，同时也要防止教师偏差被继承。接下来由 B 讲具体案例：这个范式如何在 Depth Anything 里解决单目深度估计的监督瓶颈，以及它为什么能和 Align3R 的深度对齐问题接起来。”

B 接上第 8 页

“我接着讲应用部分。我们不是突然引入 Depth Anything，而是从 Align3R 的问题出发：视频几何需要稳定深度，但真实深度标注不足。Depth Anything 正好提供了一种教师-学生式的解决方案。”

可能被问到的问题

1. 教师模型一定有人工标签吗？

不一定。教师可能先用有标签数据训练，也可能来自 EMA 平均、模型集成、预训练编码器，或者合成数据训练。它的作用是产生监督信号。对于无标签数据，教师可以生成伪标签，学生再用这些伪标签训练。

2. 学生最后会输出语义吗？

在 Depth Anything 中不会。学生最终输出的是深度图。但通过 DINOv2 的特征对齐，学生中间表示会吸收语义结构，比如物体边界、区域一致性和前景背景关系。简洁说法是：学生不输出语义，而是使用语义来预测深度。

3. 伪标签不准怎么办？

常见做法包括置信度过滤、强数据增强、一致性约束、少量真值校准，以及提高教师本身质量。Depth Anything v2 就是提高教师标签质量的例子。

4. 学生可能超过教师吗？

可能，但原因不是学生天然更强，而是学生训练时可能看到更多数据、更强扰动，或者拥有更合适的结构。大量伪标签和增强训练可能让学生在某些测试集上表现超过原教师。

5. Depth Anything 和 Align3R 的关系怎么讲？

Depth Anything 提供强单帧深度先验；Align3R 关注如何把单帧深度在动态视频中对齐成时间一致的几何表示。前者解决“深度从哪里来”，后者解决“深度如何跨帧一致”。